

Labor Matlab für die industrielle und medizinische Bildverarbeitung

Prof. Dr.-Ing. Bodo Rosenhahn

Institut für Informationsverarbeitung





Einleitung

- 20.10. Introduction (1h VL, 3 L), Accountvergabe (Präsenz)
- 27.10. Local operators (Harris, etc.) (1h VL, 3L)
- 03.11. Global Operators (Hough Transform) (1h VL, 3L)
- 10.11. Region Growing / Watershed Segmentation (1h VL, 3L)
- 17.11. Bayes Classifier (1h VL, 3L)
- 24.11. K-Means / Mean shift (1h VL, 3L)
- 01.12. Shape Context (1h VL, 3L)
- 08.12. Morphological Operators (1h VL, 3L)
- 15.12. Disparity estimation (DTW) (1h VL, 3L)
- 22.12. Restarbeiten vor Weihnachten (4L)
- 12.01. Calibration and Triangulation (1h VL, 3L)
- 19.01. PCA (1h VL, 3L)
- 26.01. Tracking (1h VL, 3L)

Statistics ...

... Emotions



Bayes Classifier

Ein **Bayes-Klassifikator** (Aussprache: [bɛi:z], benannt nach dem englischen Mathematiker Thomas Bayes), ist ein aus dem Bayestheorem hergeleiteter Klassifikator.

Ein Bayes-Klassifikator b ist eine Funktion, die Vektoren aus einem f -dimensionalen reellwertigen Merkmalsraum auf eine Menge von Klassen C abbildet:

$$b: \mathbb{R}^f \rightarrow C$$

Die Funktion wird realisiert durch die Maximierung der A-Posteriori-WK gegeben die Merkmale. D.h. Eine (mögliche) Entscheidungsregel lautet „Wähle die Klasse die am wahrscheinlichsten ist.“

$$p(C|F_1, \dots, F_n)$$

<http://de.wikipedia.org/wiki/Bayes-Klassifikator>

Probabilistische Erkennung


Modelliere Wahrscheinlichkeitsdichten und wende Sätze aus der Statistik an, um eine möglichst sichere Aussage über die Erkennung machen zu können.

Definition (Wahrscheinlichkeit, Wahrscheinlichkeitsmaß):

Die Wahrscheinlichkeit $P(\psi_j)$ ist eine reelle Zahl $0 \leq P(\psi_j) \leq 1$, die jedem Element ψ_j des Ereignisfeldes Ω eindeutig zugeordnet werden kann.


Es gilt also:

1. P ist nicht negativ: $P(\psi) \geq 0 \forall \psi \in \Omega$
2. P ist normiert: $P(\Omega) = 1$
3. P ist additiv: $P(\psi_j \cup \psi_k) = P(\psi_j) + P(\psi_k)$
falls $\psi_j \cap \psi_k = \emptyset$



Grundlagen

Event	Probability
A	$P(A) \in [0, 1]$
not A	$P(A^c) = 1 - P(A)$
A or B	$P(A \cup B) = P(A) + P(B) - P(A \cap B)$ $P(A \cup B) = P(A) + P(B)$ if A and B are mutually exclusive
A and B	$P(A \cap B) = P(A B)P(B) = P(B A)P(A)$ $P(A \cap B) = P(A)P(B)$ if A and B are independent
A given B	$P(A B) = \frac{P(A \cap B)}{P(B)} = \frac{P(B A)P(A)}{P(B)}$



<https://en.wikipedia.org/wiki/Probability>

Definition (bedingte Wahrscheinlichkeit):

Die Wahrscheinlichkeit von Φ_j unter der Bedingung, dass Φ_k bereits eingetreten ist, heißt die bedingte Wahrscheinlichkeit von Φ_j unter der Bedingung Φ_k :

$$P(\Phi_j | \Phi_k) = \frac{P(\Phi_j, \Phi_k)}{P(\Phi_k)} \quad \text{für} \quad P(\Omega_k) > 0$$

Hieraus folgt die *Multiplikationsregel*:

$$P(\Phi_j \cap \Phi_k) = P(\Phi_j | \Phi_k) P(\Phi_k) = P(\Phi_k | \Phi_j) P(\Phi_j)$$

Definition (totale Wahrscheinlichkeit):

Bilden die Ereignisse $\Phi_k, k = 1, 2, \dots, n$ im Ereignisfeld A ein vollständiges System von Ereignissen, dann erhält man für ein Ereignis $\Phi_j \in A$ die totale Wahrscheinlichkeit $P(\Phi_j)$ mit den bedingten Wahrscheinlichkeiten $P(\Phi_j | \Phi_k), k = 1, \dots, n$ zu

$$P(\Phi_j) = \sum_{k=1}^n P(\Phi_j | \Phi_k) P(\Phi_k)$$

Formel von Bayes:

$$P(\Phi_i | \Phi_0) = \frac{P(\Phi_0 | \Phi_i) P(\Phi_i)}{\sum_{k=1}^n P(\Phi_0 | \Phi_k) P(\Phi_k)}$$

Der Satz von Bayes

$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$

posterior
probability

likelihood

prior probability

Eine der wichtigsten Regeln aus dem Bereich Machine Learning:
Sie erlaubt die Ausgabe der Wahrscheinlichkeit von Y gegeben die
Messungen X .

Im Training hat man die umgekehrte Information: Die Wahrscheinlich-
keit des Auftretens von Y (prior) und die Auswertung einer Messung
(likelihood), X .

(Die likelihood evaluiert eine mögliche Messung.)
Maximierung der likelihood nennt man:
Maximum likelihood Schätzung (ML)

Wahrscheinlichkeit eines Objektes o gegeben einen Feature Vektor m

$$p(o_n | m_k) = \frac{p(m_k | o_n) p(o_n)}{p(m_k)} = \frac{p(m_k | o_n) p(o_n)}{\sum_i p(m_k | o_i) p(o_i)}$$

$p(o)$: Wahrscheinlichkeit des Auftretens von Objekt o (z.B. Gleichverteilung)

$p(m)$: Wahrscheinlichkeit des Auftretens von Feature-Vektor m

$p(m/o)$: Wahrscheinlichkeit von m gegeben o

Bayes Classifier

Bei einem „Naiven Bayes Classifier“ wird die Grundannahme gemacht, dass jedes Attribut nur vom Klassenattribut abhängt.

Die Bayes-Regel ergibt dann:

$$p(C | F_1, \dots, F_n) = \frac{1}{Z} p(C) \prod_{i=1}^n p(F_i | C)$$

Z ist ein Skalierungsfaktor (Evidenz)

<http://de.wikipedia.org/wiki/Bayes-Klassifikator>

Bayes Classifier

Wie *lernt* man die WK aus Beispielen ?

- Nehme kontinuierliches Modell an
- Nehme z.B. Gaussverteilung an
- Bestimme mean und variance aus Trainingsdaten

$$\begin{array}{ccc} \mu_c & & \sigma_c^2 \\ \longrightarrow & P(x = v | c) = & \frac{1}{\sqrt{2\pi\sigma_c^2}} e^{-\frac{(v-\mu_c)^2}{2\sigma_c^2}} \end{array}$$

Prior:

$P(c) = 1 / (\# \text{ Klassen})$ oder

$P(c) = (\# \text{ Beispiele aus der Klasse}) / (\# \text{ Beispiele})$

<http://de.wikipedia.org/wiki/Bayes-Klassifikator>

Bayes Classifier

Die Maximum A-posteriori-WK-Regel (MAP) lautet:

$$\text{classify}(f_1, \dots, f_n) = \arg \max_c p(C = c) \prod_{i=1}^n p(F_i = f_i | C = c).$$

<http://de.wikipedia.org/wiki/Bayes-Klassifikator>

Beispiel: Gender-Klassifikation

sex	height (feet)	weight (lbs)	foot size(inches)
male	6	180	12
male	5.92 (5'11")	190	11
male	5.58 (5'7")	170	12
male	5.92 (5'11")	165	10
female	5	100	6
female	5.5 (5'6")	150	8
female	5.42 (5'5")	130	7
female	5.75 (5'9")	150	9

<http://de.wikipedia.org/wiki/Bayes-Klassifikator>

Beispiel: Gender-Klassifikation

sex	mean (height)	variance (height)	mean (weight)	variance (weight)	mean (foot size)	variance (foot size)
male	5.855	3.5033e-02	176.25	1.2292e+02	11.25	9.1667e-01
female	5.4175	9.7225e-02	132.5	5.5833e+02	7.5	1.6667e+00

Prior:

$$P(\text{male}) = P(\text{female}) = 0.5$$

<http://de.wikipedia.org/wiki/Bayes-Klassifikator>

Wahrscheinlichkeit eines Objektes o gegeben einen Feature Vektor m

$$p(o_n | m_k) = \frac{p(m_k | o_n) p(o_n)}{p(m_k)} = \frac{p(m_k | o_n) p(o_n)}{\sum_i p(m_k | o_i) p(o_i)}$$

$p(o)$: Wahrscheinlichkeit des Auftretens von Objekt o (z.B. Gleichverteilung)

$p(m)$: Wahrscheinlichkeit des Auftretens von Feature-Vektor m

$p(m/o)$: Wahrscheinlichkeit von m gegeben o

Beispiel: Gender-Klassifikation

Welches Geschlecht hat wohl eine Person mit den folgenden Daten ?

sex	height (feet)	weight (lbs)	foot size(inches)
sample	6	130	8

In Worten:

posterior (male) = $P(\text{male}) * P(\text{height} \mid \text{male}) * P(\text{weight} \mid \text{male}) * P(\text{foot size} \mid \text{male}) / \text{evidence}$

posterior (female) = $P(\text{female}) * P(\text{height} \mid \text{female}) * P(\text{weight} \mid \text{female}) * P(\text{foot size} \mid \text{female}) / \text{evidence}$

evidence = $P(\text{male}) * P(\text{height} \mid \text{male}) * P(\text{weight} \mid \text{male}) * P(\text{foot size} \mid \text{male}) + P(\text{female}) * P(\text{height} \mid \text{female}) * P(\text{weight} \mid \text{female}) * P(\text{foot size} \mid \text{female})$

<http://de.wikipedia.org/wiki/Bayes-Klassifikator>

Beispiel: Gender- Klassifikation

$$P(\text{male}) = 0.5$$

$$P(\text{height} \mid \text{male}) = 1.5789$$

$$P(\text{weight} \mid \text{male}) = 5.9881\text{e-}06$$

$$P(\text{foot size} \mid \text{male}) = 1.3112\text{e-}3$$

$$\text{posterior numerator (male)} = \text{Produkt} = 6.1984\text{e-}09$$

$$P(\text{female}) = 0.5$$

$$P(\text{height} \mid \text{female}) = 2.2346\text{e-}1$$

$$P(\text{weight} \mid \text{female}) = 1.6789\text{e-}2$$

$$P(\text{foot size} \mid \text{female}) = 2.8669\text{e-}1$$


$$\text{posterior numerator (female)} = \text{Produkt} = 5.3778\text{e-}04$$

Entscheidung: Female

$$p(C \mid F_1, \dots, F_n) = \frac{1}{Z} p(C) \prod_{i=1}^n p(F_i \mid C)$$

<http://de.wikipedia.org/wiki/Bayes-Klassifikator>


Confusion Matrix



Confusion Matrix

		CONDITION determined by "Gold Standard"			
TOTAL POPULATION		CONDITION POS	CONDITION NEG	PREVALENCE $\frac{\text{CONDITION POS}}{\text{TOTAL POPULATION}}$	
TEST OUT- COME	TEST POS	True Pos TP	Type I Error False Pos FP	Precision Pos Predictive Value $\text{PPV} = \frac{\text{TP}}{\text{TEST P}}$	False Discovery Rate $\text{FDR} = \frac{\text{FP}}{\text{TEST P}}$
	TEST NEG	Type II Error False Neg FN	True Neg TN	False Omission Rate $\text{FOR} = \frac{\text{FN}}{\text{TEST N}}$	Neg Predictive Value $\text{NPV} = \frac{\text{TN}}{\text{TEST N}}$
ACCURACY ACC $\text{ACC} = \frac{\text{TP} + \text{TN}}{\text{TOT POP}}$		Sensitivity (SN), Recall Total Pos Rate TPR $\text{TPR} = \frac{\text{TP}}{\text{CONDITION POS}}$	Fall-Out False Pos Rate FPR $\text{FPR} = \frac{\text{FP}}{\text{CONDITION NEG}}$	Pos Likelihood Ratio LR + $\text{LR} + = \frac{\text{TPR}}{\text{FPR}}$	Diagnostic Odds Ratio DOR $\text{DOR} = \frac{\text{LR} +}{\text{LR} -}$
		Miss Rate False Neg Rate FNR $\text{FNR} = \frac{\text{FN}}{\text{CONDITION POS}}$	Specificity (SPC) True Neg Rate TNR $\text{TNR} = \frac{\text{TN}}{\text{CONDITION NEG}}$	Neg Likelihood Ratio LR - $\text{LR} - = \frac{\text{TNR}}{\text{FNR}}$	


Image Bayes Classifier




s. Matlab Beispiel

Image Bayes Classifier

Feature-Antwort



Likelihood



→ Mean / Variance

Image Bayes Classifier

Entscheidungsebene + Feature-Antwort




Image Bayes Classifier

Detektionen




Image Bayes Classifier

Detektionen nach Mean-shift

